

ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN



Hội quy tuổi dựa trên đặc trưng khuôn mặt

Học phần: Thị giác máy tính

Giảng viên hướng dẫn: TS Cao Văn Chung

Cao Hải An 23001818

Đặng Thế Anh 23001821

Đỗ Minh Đức 23001864

Hà Nội - 2025

Mục lục

1	Mở đầu	1
1.1	Đặt vấn đề	1
1.2	Giới thiệu bài toán	1
1.3	Mục tiêu	2
2	Cơ sở lí thuyết	3
2.1	Các phương pháp trích xuất đặc trưng	3
2.1.1	Histogram of Oriented Gradients (HOG)	3
2.1.2	Local Binary Pattern (LBP)	3
2.1.3	Scale-Invariant Feature Transform (SIFT)	3
2.2	Các mô hình học máy	3
2.2.1	SVR	3
2.2.2	Random Forest	3
2.2.3	Multi-Layer perceptron regression	3
2.3	Principal Component Analysis (PCA)	3
3	Thực nghiệm và Kết quả	4
3.1	Bộ dữ liệu	4
3.1.1	Phân tích toàn bộ tập dữ liệu	5
3.1.2	Phân tích theo từng chủng tộc	9
3.2	Thiết lập thực nghiệm	11
3.2.1	Môi trường phần cứng	11
3.2.2	Tiền xử lý dữ liệu	11
3.2.3	Trích xuất đặc trưng	12

3.2.4	Cấu hình mô hình và Tham số huấn luyện	12
3.2.5	Tiêu chí đánh giá	13
3.3	Kết quả thực nghiệm	14
3.3.1	So sánh hiệu năng các phương pháp trích xuất đặc trưng	14
4	Thảo luận	17
4.1	Phân tích lỗi sai	17
4.1.1	Sai số theo nhóm tuổi	17
4.1.2	Sai số theo giới tính	17
4.1.3	Sai số theo chủng tộc	18
4.1.4	Đánh giá phương pháp huấn luyện chung và riêng rẽ .	21
4.2	Phân tích khả năng giảm chiều dữ liệu	21
5	Kết luận	25

Danh sách hình vẽ

3.1	Phân phối độ tuổi toàn bộ tập dữ liệu UTKFace.	6
3.2	Phân bố số lượng ảnh theo nhóm tuổi.	7
3.3	Tỷ lệ giới tính trong toàn bộ tập dữ liệu.	8
3.4	Đường cong mật độ độ tuổi theo giới tính.	8
3.5	Phân bố số lượng mẫu theo chủng tộc.	9
3.6	Cấu trúc giới tính bên trong từng nhóm chủng tộc.	10
3.7	Mật độ và phân tán độ tuổi trên từng nhóm chủng tộc.	10
3.8	Biểu đồ so sánh RMSE và MAE của 3 phương pháp trích xuất đặc trưng với 3 mô hình học máy.	15
3.9	Biểu đồ phân tán (Scatter Plot) giữa tuổi thực tế và tuổi dự đoán của mô hình HOG + MLP.	16
4.1	Sai số dự đoán (MAE) phân loại theo từng nhóm tuổi.	17
4.2	Sai số dự đoán (MAE) phân loại theo giới tính.	18
4.3	Sai số dự đoán (MAE) trung bình theo từng chủng tộc.	18
4.4	Mật độ và phân tán của sai số dự đoán theo từng chủng tộc.	19
4.5	Phân tích MAE theo nhóm tuổi cho từng chủng tộc.	20
4.6	So sánh MAE khi huấn luyện chung toàn bộ dữ liệu và huấn luyện riêng rẽ cho từng chủng tộc.	21
4.7	So sánh sai số RMSE theo số lượng thành phần chính (PCA) trên 3 mô hình.	22

Danh sách bảng

3.1	Thống kê mô tả độ tuổi toàn cục trên tập UTKFace.	5
3.2	Kết quả đánh giá các cấu hình đặc trưng và mô hình.	14
4.1	Đánh giá RMSE của các mô hình theo mức độ giảm chiều PCA.	23

Chương 1. Mở đầu

1.1 Đặt vấn đề

Hồi quy tuổi từ khuôn mặt là một bài toán quan trọng trong thị giác máy tính vì nó hỗ trợ nhiều ứng dụng thực tế như quảng cáo theo độ tuổi, phân tích nhân khẩu học, kiểm soát truy cập và cá nhân hoá trải nghiệm người dùng. Nhiều hướng tiếp cận hiện đại cho thấy việc dự đoán tuổi từ ảnh khuôn mặt là khả thi, nhưng vẫn còn khó khăn lớn do sự thay đổi về biểu cảm, góc chụp, ánh sáng và khác biệt cá nhân trong quá trình lão hoá [1, 2].

Việc xây dựng mô hình hồi quy tuổi chính xác đòi hỏi trích xuất đặc trưng khuôn mặt phù hợp và thiết kế mô hình có khả năng biểu diễn mối quan hệ phi tuyến giữa đặc trưng và tuổi thực. Ngoài ra, dữ liệu huấn luyện thường bị lệch theo phân bố tuổi hoặc chứa nhãn không hoàn toàn chính xác, khiến khả năng tổng quát hoá của mô hình bị ảnh hưởng đáng kể [3, 1].

1.2 Giới thiệu bài toán

Bài toán của project này là xây dựng và đánh giá phương pháp hồi quy tuổi dựa trên ảnh khuôn mặt. Mục tiêu là tạo ra một mô hình có thể dự đoán tuổi dưới dạng giá trị liên tục, thay vì chỉ phân lớp tuổi, để phản ánh sát hơn sự biến thiên thực tế giữa các cá nhân. Cụ thể, bài toán bao gồm:

- Xây dựng pipeline trích xuất đặc trưng khuôn mặt (ví dụ: CNN pre-trained, biểu diễn mặt khuôn, các kỹ thuật tiền xử lý như cân bằng sáng, căn vùng khuôn mặt).
- Thiết kế mô hình hồi quy (mạng nơ-ron tích chập, mô hình kết hợp hoặc phương pháp ensemble) để dự đoán tuổi dưới dạng giá trị thực.
- Xử lý vấn đề dữ liệu: bình thường hoá nhãn tuổi, xử lý nhãn nhiễu, và cân bằng lớp tuổi khi cần.
- Đánh giá hiệu năng trên các bộ dữ liệu chuẩn theo các chỉ số MSE/MAE và so sánh với các phương pháp tham chiếu.

Bài toán yêu cầu cân bằng giữa độ chính xác dự đoán và khả năng tổng quát hoá trên ảnh ngoài bộ huấn luyện, đồng thời cần xem xét các yếu tố đạo đức và riêng tư khi sử dụng ảnh khuôn mặt. Đây là lý do project này có ý nghĩa thực tiễn rõ ràng và cần được triển khai cẩn thận từ khâu dữ liệu đến đánh giá mô hình.

1.3 Mục tiêu

Mục tiêu tổng quát của project là phát triển một giải pháp hồi quy tuổi từ ảnh khuôn mặt có độ chính xác cao và khả năng tổng quát hoá tốt trên nhiều điều kiện chụp khác nhau.

Mục tiêu cụ thể:

- Thiết kế pipeline tiền xử lý và trích xuất đặc trưng khuôn mặt phù hợp cho nhiệm vụ hồi quy tuổi.
- Triển khai và huấn luyện mô hình hồi quy (ví dụ: CNN với đầu ra liên tục) và tối ưu hàm mất mát phù hợp cho bài toán hồi quy.
- Xử lý vấn đề dữ liệu như cân bằng phân phối tuổi, lọc nhãn sai và tăng cường dữ liệu.
- Đánh giá mô hình bằng các chỉ số như MAE (Mean Absolute Error) và RMSE trên các bộ dữ liệu chuẩn, so sánh với các phương pháp liên quan đã công bố [1, 3, 4].
- Thảo luận các yếu tố đạo đức, riêng tư và hạn chế của phương pháp.

Phần còn lại của chương sẽ trình bày các khái niệm cơ bản về học sâu cho hồi quy, các bộ dữ liệu chuẩn cho bài toán tuổi và tổng quan các công trình liên quan.

Chương 2. Cơ sở lí thuyết

2.1 Các phương pháp trích xuất đặc trưng

2.1.1 Histogram of Oriented Gradients (HOG)

2.1.2 Local Binary Pattern (LBP)

2.1.3 Scale-Invariant Feature Transform (SIFT)

2.2 Các mô hình học máy

2.2.1 SVR

2.2.2 Random Forest

2.2.3 Multi-Layer perceptron regression

2.3 Principal Component Analysis (PCA)

Chương 3. Thực nghiệm và Kết quả

Chương này trình bày chi tiết về toàn bộ quá trình thực nghiệm nhằm đánh giá hiệu năng của các phương pháp đề xuất. Nội dung chương bao gồm phân tích đặc điểm bộ dữ liệu UTKFace, mô tả quy trình thiết lập môi trường và cấu hình tham số cho các mô hình học máy. Cuối cùng, các kết quả dự đoán tuổi thực tế sẽ được tổng hợp, trực quan hóa và so sánh dựa trên các độ đo sai số chuẩn (RMSE, MAE) để từ đó lựa chọn ra mô hình tối ưu nhất cho bài toán.

3.1 Bộ dữ liệu

Trong tiểu luận này, tập dữ liệu sử dụng cho bài toán hồi quy tuổi là UTKFace [5], một bộ ảnh khuôn mặt công khai được lấy từ Kaggle. Tập dữ liệu này chứa tổng cộng 23.705 ảnh, mỗi ảnh đi kèm nhãn được mã hóa trực tiếp trong tên tệp theo mẫu:

`[age]_[gender]_[race]_[date&time].jpg`

Trong đó:

- **age** là tuổi của đối tượng, được biểu diễn bởi một số nguyên từ 0 đến 116.
- **gender** nhận giá trị 0 cho nam và 1 cho nữ.
- **race** nhận giá trị từ 0 đến 4, tương ứng với White, Black, Asian, Indian và Others.
- **date&time** là dấu thời gian thu thập ảnh theo định dạng `yyyymmddHHMMSSFFF`.

Việc nhãn được nhúng sẵn trong tên ảnh giúp quá trình xây dựng tập dữ liệu thuận tiện hơn vì không cần gán nhãn thủ công. Tuy nhiên, cách tổ chức này cũng đòi hỏi bước tiền xử lý cẩn thận để đọc đúng nhãn, loại bỏ các tệp lỗi và kiểm tra những mẫu có thông tin bất thường. Trong bài toán này, nhãn tuổi là đầu ra chính cần dự đoán; còn giới tính và chủng tộc được dùng

như thông tin bổ sung để phân tích phân bố dữ liệu, đánh giá mức độ phụ thuộc của dữ liệu vào hai yếu tố này dựa trên đặc điểm ảnh, và xem xét ảnh hưởng của chúng đến kết quả dự đoán tuổi.

3.1.1 Phân tích toàn bộ tập dữ liệu


Bảng 3.1 tóm tắt nhanh các thống kê mô tả của biến tuổi trên toàn bộ 23.705 ảnh. Có thể thấy tuổi trung bình là 33.30, trung vị là 29 và độ lệch chuẩn xấp xỉ 19.89, cho thấy phân bố tuổi có độ phân tán lớn.

Bảng 3.1: Thống kê mô tả độ tuổi toàn cục trên tập UTKFace.

Count	Mean	Std	Min	25%	50% (Median)	75%	Max
23705	33.300907	19.885708	1	23	29	45	116


Biểu đồ ở Hình 3.1 cho thấy phân bố tuổi của toàn bộ tập dữ liệu không đồng đều. Phần lớn ảnh tập trung trong khoảng 21–40 tuổi, với đỉnh phân bố rơi vào vùng 25–30 tuổi. Ngoài cụm chính này, tập dữ liệu vẫn có một lượng ảnh đáng kể ở nhóm trẻ nhỏ từ 0–5 tuổi và một đuôi phân bố kéo dài về phía các độ tuổi lớn hơn 60.

Sự lệch phân bố này có ý nghĩa quan trọng đối với bài toán hồi quy tuổi. Nếu mô hình được huấn luyện trực tiếp trên dữ liệu gốc mà không có cơ chế cân bằng hoặc tăng cường dữ liệu, mô hình có xu hướng học tốt hơn ở các nhóm tuổi xuất hiện nhiều, đặc biệt là nhóm người trưởng thành trẻ, trong khi dễ sai lệch hơn ở các nhóm rất trẻ hoặc rất già.



Hình 3.1: Phân phối độ tuổi toàn bộ tập dữ liệu UTKFace.


Phân bố theo nhóm tuổi. Để nhìn rõ hơn mức độ mất cân bằng dữ liệu, tuổi được gom thành các nhóm rời rạc. Hình 3.2 cho thấy nhóm 21–30 tuổi chiếm ưu thế rất lớn với khoảng 7.7 nghìn ảnh, tiếp theo là nhóm 31–40 tuổi với khoảng 4.3 nghìn ảnh. Nhóm 0–5 tuổi cũng có số lượng tương đối lớn, trong khi nhóm 80+ chỉ chiếm một phần rất nhỏ của tập dữ liệu.




Hình 3.2: Phân bố số lượng ảnh theo nhóm tuổi.

Phân bố giới tính. Hình 3.3 cho thấy tập dữ liệu khá cân bằng về giới tính, với nam chiếm khoảng 52.3% và nữ chiếm khoảng 47.7%.

Tuy nhiên, đường mật độ trong Hình 3.4 chỉ ra rằng phân bố tuổi giữa hai giới không hoàn toàn giống nhau. Nhóm nữ tập trung mạnh hơn quanh vùng 20–35 tuổi, trong khi nhóm nam có độ trải rộng lớn hơn và kéo dài nhiều hơn về các độ tuổi cao. Điều này cho thấy nếu mô hình mắc lỗi khác nhau giữa nam và nữ, nguyên nhân không chỉ đến từ số lượng ảnh mà còn đến từ hình thái dữ liệu và cấu trúc độ tuổi đi kèm mỗi nhóm.




Hình 3.3: Tỷ lệ giới tính trong toàn bộ tập dữ liệu.




Hình 3.4: Đường cong mật độ độ tuổi theo giới tính.

3.1.2 Phân tích theo từng chủng tộc

Phân bố theo chủng tộc trong UTKFace cũng thể hiện sự mất cân bằng khá rõ. Hình 3.5 cho thấy nhóm White chiếm tỷ lệ lớn nhất với khoảng 42.5%, tiếp theo là Black (19.1%), Indian (16.8%), Asian (14.5%) và Others (7.1%). Khi nhìn theo giới tính ở Hình 3.6, có thể thấy White vẫn là nhóm áp đảo ở cả nam lẫn nữ, trong khi các nhóm còn lại có số lượng nhỏ hơn nhiều.




Hình 3.5: Phân bố số lượng mẫu theo chủng tộc.



Hình 3.6: Cấu trúc giới tính bên trong từng nhóm chủng tộc.

Tương quan giữa tuổi và chủng tộc. Biểu đồ violin ở Hình 3.7 cho thấy độ tuổi của từng nhóm chủng tộc có sự phân tán khác nhau. Nhóm White có dải tuổi rộng nhất, bao phủ cả người trẻ, trung niên và cao tuổi. Các nhóm Asian và Others lại tập trung nhiều hơn ở các độ tuổi trẻ và trung niên, trong khi số mẫu ở độ tuổi rất cao tương đối ít. Điều này phản ánh không chỉ sự khác biệt về phân bố dữ liệu mà còn cho thấy một số vùng tuổi - chủng tộc có mật độ mẫu thấp hơn đáng kể so với phần còn lại của tập dữ liệu.



Hình 3.7: Mật độ và phân tán độ tuổi trên từng nhóm chủng tộc.

Từ các biểu đồ trên có thể rút ra các nhận xét chính. Thứ nhất, UTKFace là bộ dữ liệu đủ lớn và có nhân phong phú, phù hợp cho bài toán hồi quy tuổi. Thứ hai, phân bố tuổi không đồng đều, đặc biệt tập trung mạnh ở nhóm 21–40 tuổi, nên mô hình dễ thiên lệch về vùng tuổi này. Thứ ba, dữ liệu tồn tại mất cân bằng theo chủng tộc và sự khác biệt về phân bố tuổi giữa các nhóm nhân khẩu học, vì vậy cần đánh giá mô hình theo nhiều góc nhìn khác nhau.

3.2 Thiết lập thực nghiệm

3.2.1 Môi trường phần cứng

Các thí nghiệm được thực hiện trên máy tính cá nhân với cấu hình phần cứng như sau:

- **CPU:** AMD Ryzen AI 7 350 (8 CPUs - 16 threads), 2.0GHz
- **RAM:** 32 GB

3.2.2 Tiền xử lý dữ liệu

Dữ liệu từ UTKFace được xử lý theo hai bước chính: chia tập và tiền xử lý ảnh.

Chia tập dữ liệu. Để đảm bảo tính cân bằng giữa các nhóm nhân khẩu học, tập dữ liệu được chia thành train (80%) và test (20%) bằng stratified splitting. Cụ thể, một khóa stratification được tạo bằng cách kết hợp chủng tộc (race) và nhóm tuổi (age_group), đảm bảo mỗi tổ hợp race-age_group xuất hiện ở cả tập train lẫn test với tỷ lệ tương đương. Trước khi chia, những nhóm có quá ít mẫu (ít hơn 2 ảnh) được loại bỏ để tránh lỗi stratification. Các chỉ số tập train và test được lưu để sử dụng lại trong các thí nghiệm.

Tiền xử lý ảnh. Mỗi ảnh đầu vào trải qua pipeline tiền xử lý như sau:

1. **Đọc ảnh:** Sử dụng OpenCV để đọc ảnh từ đường dẫn. Nếu đọc thất bại, trả về ảnh đen kích thước chuẩn hóa.
2. **Khử nhiễu:** Áp dụng Gaussian Blur với kernel 3×3 để giảm nhiễu và làm mượt ảnh.

3. **Chuẩn hóa kích thước:** Resize ảnh về kích thước chuẩn định (128×128) bằng phương pháp `INTER_AREA`.
4. **Chuyển đổi không gian màu:** Ảnh được chuyển từ BGR (mặc định OpenCV) sang Grayscale.

Sau tiền xử lý, ảnh được đưa qua bước trích xuất đặc trưng trước khi đưa vào huấn luyện mô hình.

3.2.3 Trích xuất đặc trưng

Thay vì sử dụng trực tiếp toàn bộ giá trị pixel của ảnh làm đầu vào, các đặc trưng cục bộ được trích xuất nhằm nâng cao khả năng biểu diễn thông tin và độ mạnh mẽ của mô hình. Có 3 phương pháp trích xuất đặc trưng được cài đặt và so sánh:

- **HOG (Histogram of Oriented Gradients):** Trích xuất đặc trưng định hướng gradient với số lượng hướng là 9. Cấu hình được đặt là 8×8 pixels cho mỗi cell và 2×2 cells cho mỗi block. Quá trình chuẩn hóa block sử dụng chuẩn L2-Hys.
- **LBP (Local Binary Pattern):** Trích xuất đặc trưng kết cấu cục bộ bằng phương pháp LBP uniform, với bán kính lân cận $R = 1$ và số điểm mẫu $P = 8$. Vector đặc trưng cuối cùng là một biểu đồ tần suất (histogram) đã được chuẩn hóa L1 của các giá trị LBP trên toàn ảnh.
- **SIFT (Scale-Invariant Feature Transform):** Sử dụng thuật toán SIFT để phát hiện và trích xuất các điểm đặc trưng cục bộ. Vector đặc trưng đại diện cho mỗi ảnh được tính bằng trung bình (mean) của toàn bộ các SIFT descriptors được tìm thấy trong ảnh đó.

3.2.4 Cấu hình mô hình và Tham số huấn luyện

Dữ liệu đặc trưng thu được từ các phương pháp trên sẽ được dùng để huấn luyện độc lập trên 3 mô hình hồi quy học máy khác nhau:

- **SVR (Support Vector Regression):** Sử dụng nhân (kernel) RBF, với tham số phạt $C = 1.0$. Dữ liệu đầu vào được chuẩn hóa bằng

`StandardScaler` trước khi đi vào mô hình SVR.

- **Random Forest Regressor:** Mô hình học máy dạng tập hợp (ensemble) cấu tạo từ 100 cây quyết định (`n_estimators=100`). Độ sâu tối đa của mỗi cây được giới hạn ở mức 10 (`max_depth=10`). Mô hình chạy đa luồng (`n_jobs=-1`) để tăng tốc xử lý.
- **MLP (Multi-layer Perceptron):** Mạng nơ-ron truyền thẳng gồm 2 tầng ẩn với số lượng nơ-ron lần lượt là 256 và 128. Mô hình sử dụng hàm kích hoạt ReLU, thuật toán tối ưu hóa Adam, và hệ số chuẩn hóa regularization $\alpha = 0.001$. Quá trình huấn luyện kéo dài tối đa 200 epochs. Tương tự SVR, dữ liệu đi vào MLP cũng được chuẩn hóa bằng `StandardScaler`.

3.2.5 Tiêu chí đánh giá

Hiệu năng dự đoán tuổi của các mô hình được đo lường thông qua 2 độ đo chính:

- **RMSE (Root Mean Square Error):** Căn bậc hai của sai lệch bình phương trung bình, phản ánh độ lệch chuẩn của phần dư. Việc bình phương sai số trước khi tính trung bình giúp RMSE phạt nặng hơn những dự đoán có sai số lớn. Công thức tính:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (3.1)$$

- **MAE (Mean Absolute Error):** Độ sai lệch tuyệt đối trung bình giữa tuổi dự đoán và tuổi thực tế. MAE mang ý nghĩa trực quan cao, cho biết trung bình mô hình dự đoán sai lệch bao nhiêu tuổi so với nhãn gốc. Công thức tính:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (3.2)$$

Trong đó, n là tổng số mẫu dữ liệu đánh giá, y_i là tuổi thực tế (ground truth) và $\hat{y}_i$ là tuổi do mô hình dự đoán của mẫu thứ i .

3.3 Kết quả thực nghiệm

3.3.1 So sánh hiệu năng các phương pháp trích xuất đặc trưng


Thực nghiệm được tiến hành bằng cách kết hợp chéo 3 loại đặc trưng (HOG, LBP, SIFT) với 3 mô hình học máy (SVR, Random Forest, MLP). Kết quả đánh giá hiệu năng trên tập kiểm thử (RMSE, MAE) và thời gian huấn luyện tương ứng được trình bày chi tiết trong Bảng 3.2.

Bảng 3.2: Kết quả đánh giá các cấu hình đặc trưng và mô hình.

Đặc trưng	Mô hình	RMSE	MAE	Thời gian (s)
HOG	RF	13.25	9.89	740.16
	SVR	12.65	9.15	910.99
	MLP	9.57	6.85	67.89
LBP	RF	16.37	12.43	1.02
	SVR	16.27	12.17	13.39
	MLP	15.94	12.14	32.92
SIFT	RF	17.89	13.68	12.12
	SVR	17.76	13.08	20.92
	MLP	22.31	17.19	30.10

Qua Bảng 3.2 và Hình 3.8, ta có thể rút ra một số nhận xét quan trọng:

- **Đặc trưng HOG vượt trội:** HOG cho kết quả tốt nhất ở tất cả các mô hình. Sự kết hợp giữa HOG và mạng nơ-ron đa tầng MLP đạt hiệu năng cao nhất trên toàn bộ thực nghiệm với MAE chỉ 6.85 tuổi. Điều này cho thấy định hướng gradient của HOG nắm bắt rất tốt hình thái nếp nhăn và đường nét cấu trúc khuôn mặt - những yếu tố cốt lõi để nhận diện độ tuổi.
- **LBP và SIFT kém hiệu quả hơn:** LBP mô tả tốt kết cấu bề mặt cục bộ nhưng thiếu thông tin về hình dáng tổng thể, dẫn đến sai số tương đối cao (MAE > 12). SIFT thậm chí cho kết quả thấp nhất, đặc biệt khi




Hình 3.8: Biểu đồ so sánh RMSE và MAE của 3 phương pháp trích xuất đặc trưng với 3 mô hình học máy.

kết hợp với MLP ($MAE = 17.19$). Việc tính trung bình (mean) tất cả các SIFT descriptors trong ảnh đã làm mất đi thông tin phân bố không gian quan trọng của khuôn mặt.

- **Đánh giá thời gian huấn luyện:** Đặc trưng HOG sinh ra vector có số chiều lớn, làm tăng đáng kể thời gian huấn luyện đối với SVR (910s) và Random Forest (740s). Ngược lại, mạng MLP lại tối ưu hóa dữ liệu cao chiều rất tốt, chỉ tốn khoảng 68s nhưng lại mang về độ chính xác vượt trội.

Từ kết quả này, cấu hình **HOG + MLP** được lựa chọn làm mô hình tốt nhất để phân tích và đánh giá chuyên sâu hơn. Hình 3.9 thể hiện biểu đồ phân tán giữa tuổi thực tế và tuổi dự đoán của mô hình này. Phần lớn các điểm phân bố bám sát đường chéo trung tâm, chứng tỏ mô hình có khả năng hồi quy tuổi khá đồng đều.




Hình 3.9: Biểu đồ phân tán (Scatter Plot) giữa tuổi thực tế và tuổi dự đoán của mô hình HOG + MLP.

Chương 4. Thảo luận

4.1 Phân tích lỗi sai

Phần này đánh giá chi tiết sai số dự đoán của mô hình tốt nhất (HOG + MLP) trên các nhóm thuộc tính nhân khẩu học để xác định các giới hạn của mô hình.

4.1.1 Sai số theo nhóm tuổi




Hình 4.1: Sai số dự đoán (MAE) phân loại theo từng nhóm tuổi.

Dựa vào Hình 4.1, sai số dự đoán có xu hướng tăng dần theo độ tuổi. Nhóm trẻ em (0-5 tuổi) có MAE thấp nhất (3.4). Nhóm thanh niên (21-30 tuổi) đạt MAE là 5.3. Ngược lại, mức sai số tăng mạnh ở các độ tuổi cao, đạt 12.7 ở nhóm 61-80 tuổi và 14.6 ở nhóm trên 80 tuổi. Sự gia tăng sai số này phản ánh độ phân tán lớn của đặc điểm lão hóa ở người cao tuổi và số lượng mẫu huấn luyện ít hơn so với nhóm thanh niên.

4.1.2 Sai số theo giới tính


Hình 4.2 cho thấy MAE của nhóm nữ là 6.71, thấp hơn so với nhóm nam là 6.97. Mức chênh lệch 0.26 là rất nhỏ. Kết quả này cho thấy mô hình dự



Hình 4.2: Sai số dự đoán (MAE) phân loại theo giới tính.

đoán đồng đều và không bị chênh lệch lớn giữa hai giới tính.


4.1.3 Sai số theo chủng tộc



Hình 4.3: Sai số dự đoán (MAE) trung bình theo từng chủng tộc.

Phân tích Hình 4.3, chủng tộc White có sai số trung bình cao nhất (MAE = 7.66), tiếp đến là Black (7.07). Các chủng tộc Asian và Others có mức sai


số thấp nhất (5.57 và 5.56).



Hình 4.4: Mật độ và phân tán của sai số dự đoán theo từng chủng tộc.


Biểu đồ violin (Hình 4.4) giải thích lý do nhóm White và Black có MAE cao: phân bố sai số của hai nhóm này có phần đuôi dài (nhiều mẫu có sai số dự đoán lên tới 40-60 tuổi). Nhóm Asian có phân bố tập trung chủ yếu ở mức sai số thấp dưới 20 tuổi.

Khi phân tích chi tiết theo từng độ tuổi trong mỗi chủng tộc (Hình 4.5), mô hình gặp khó khăn lớn nhất ở các nhóm cao tuổi thuộc các chủng tộc thiểu số. Cụ thể, nhóm 80+ của chủng tộc Others có sai số cực đại là 27.8, nhóm 80+ của Black có sai số 20.1. Nhóm White 80+ có sai số 13.9. Sự thiếu hụt dữ liệu huấn luyện cho người cao tuổi ở các chủng tộc này là nguyên nhân chính dẫn đến sai lệch lớn.



Hình 4.5: Phân tích MAE theo nhóm tuổi cho từng chủng tộc.

4.1.4 Đánh giá phương pháp huấn luyện chung và riêng rẽ




Hình 4.6: So sánh MAE khi huấn luyện chung toàn bộ dữ liệu và huấn luyện riêng rẽ cho từng chủng tộc.

Hình 4.6 so sánh hiệu năng giữa một mô hình được huấn luyện trên toàn bộ dữ liệu ("Chung") và 5 mô hình được huấn luyện độc lập trên dữ liệu của từng chủng tộc ("Riêng rẽ"). Kết quả cho thấy mô hình "Chung" đạt MAE thấp hơn ở tất cả các nhóm chủng tộc. Ví dụ, chủng tộc White giảm sai số từ 8.25 xuống 7.66; chủng tộc Indian giảm từ 7.07 xuống 6.21. Điều này chứng minh rằng việc kết hợp toàn bộ dữ liệu giúp mô hình học được các đặc điểm lão hóa tổng quát tốt hơn. Việc chia nhỏ dữ liệu để huấn luyện riêng rẽ làm giảm kích thước tập huấn luyện, dẫn đến hiệu năng dự đoán kém hơn.

4.2 Phân tích khả năng giảm chiều dữ liệu

Đặc trưng HOG có số chiều lớn, làm tăng thời gian tính toán của các mô hình như SVR và Random Forest. Phương pháp Phân tích Thành phần Chính (PCA) được sử dụng để giảm số chiều vector xuống các mức từ 10 đến 400 chiều.



Hình 4.7: So sánh sai số RMSE theo số lượng thành phần chính (PCA) trên 3 mô hình.

Bảng 4.1: Đánh giá RMSE của các mô hình theo mức độ giảm chiều PCA.

Số chiều	MLP	RF	SVR	Số chiều	MLP	RF	SVR
10	14.881	14.615	14.673	210	11.628	13.446	13.327
20	14.409	13.722	13.395	220	11.762	13.485	13.360
30	13.936	13.274	12.347	230	11.956	13.478	13.467
40	14.106	13.203	12.223	240	11.710	13.488	13.575
50	14.145	13.233	12.315	250	11.696	13.509	13.692
60	13.543	13.282	12.268	260	11.868	13.515	13.764
70	13.401	13.291	12.381	270	11.876	13.513	13.860
80	13.099	13.266	12.386	280	11.585	13.547	13.951
90	12.747	13.296	12.420	290	11.642	13.519	14.044
100	12.504	13.318	12.513	300	11.687	13.537	14.119
110	12.543	13.315	12.524	310	11.496	13.532	14.241
120	12.251	13.356	12.611	320	11.751	13.561	14.337
130	12.428	13.377	12.673	330	11.511	13.549	14.453
140	12.162	13.374	12.742	340	11.588	13.573	14.487
150	12.152	13.387	12.803	350	11.587	13.599	14.594
160	12.127	13.410	12.871	360	11.592	13.597	14.696
170	12.053	13.412	12.992	370	11.468	13.579	14.762
180	12.143	13.406	13.037	380	11.635	13.607	14.807
190	11.845	13.414	13.131	390	11.386	13.606	14.926
200	12.025	13.440	13.221	400	11.651	13.595	14.972
				Gốc (8100D)	9.570	13.250	12.650

Dựa trên dữ liệu từ Hình 4.7 và Bảng 4.1:

- **Mô hình SVR:** SVR không dùng PCA đạt RMSE 12.65. Khi nén PCA xuống 40 chiều, RMSE của SVR giảm xuống mức tối ưu là 12.223. Đồ thị Hình 4.7 cho thấy đường biểu diễn của SVR đạt đáy tại 40 chiều và tăng dần khi số chiều cao hơn. PCA loại bỏ nhiễu và thông tin thừa, giúp SVR hoạt động chính xác và nhanh hơn đáng kể.
- **Mô hình Random Forest:** Đường biểu diễn của RF đi ngang ở mức

13.2 đến 13.6 từ mốc 40 chiều trở đi, tương tự như khi dùng dữ liệu gốc. PCA không làm thay đổi lớn hiệu năng của mô hình này do bản chất cấu trúc cây quyết định (decision tree) đã bao gồm khả năng chọn lọc đặc trưng.

- **Mô hình MLP:** MLP có xu hướng giảm dần sai số khi số lượng thành phần chính tăng lên và đạt mức tốt nhất là 11.386 tại 390 chiều. Tuy nhiên, kết quả này vẫn kém xa so với RMSE 9.570 khi sử dụng dữ liệu nguyên bản chưa nén. Khác với SVR, kiến trúc mạng nơ-ron đa tầng có khả năng tự động trích xuất các đặc trưng phi tuyến ẩn sâu từ dữ liệu thô cực kỳ tốt. Việc nén dữ liệu bằng phép chiếu tuyến tính như PCA trước khi đưa vào MLP đã vô tình loại bỏ nhiều thông tin quan trọng.

Chương 5. Kết luận

Bibliography

- [1] Rasmus Rothe, Radu Timofte, and Luc Van Gool. “DEX: Deep Expectation of Apparent Age from a Single Image”. In: *Proceedings of the IEEE International Conference on Computer Vision Workshops (ICCVW)*. 2015, pp. 252–257.
- [2] Zhifei Zhang et al. “Age Progression/Regression by Conditional Adversarial Autoencoder”. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2017, pp. 5810–5818.
- [3] Gil Levi and Tal Hassner. “Age and Gender Classification Using Convolutional Neural Networks”. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*. 2015, pp. 34–42.
- [4] Zhenxing Niu et al. “Ordinal Regression with Multiple Output CNN for Age Estimation”. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2016.
- [5] *UTKFace*. Kaggle dataset. Accessed: 2026-05-02. URL: <https://www.kaggle.com/datasets/jangedoo/utkface-new>.