

ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN



NHẬN DIỆN TUỔI
TỪ ẢNH KHUÔN MẶT NGƯỜI

Học phần: Thị giác máy tính

Giảng viên hướng dẫn: TS Cao Văn Chung

Cao Hải An 23001818

Đặng Thế Anh 23001821

Đỗ Minh Đức 23001864

Hà Nội - 2025

Mục lục

Danh sách từ viết tắt	1
1 Mở đầu	2
1.1 Đặt vấn đề	2
1.2 Giới thiệu bài toán	2
1.3 Mục tiêu	3
1.4 Tổng kết chương	3
2 Cơ sở lí thuyết	4
2.1 Các phương pháp trích xuất đặc trưng	4
2.1.1 Histogram of Oriented Gradients (HOG)	4
2.1.2 Local Binary Pattern (LBP)	5
2.1.3 Scale-Invariant Feature Transform (SIFT)	6
2.2 Giảm chiều dữ liệu	7
2.2.1 Principal Component Analysis (PCA)	8
2.3 Các mô hình hồi quy	8
2.3.1 Support Vector Regression (SVR)	9
2.3.2 Random Forest	9
2.3.3 Multi-Layer Perceptron Regression	10
2.4 Tổng kết chương	11
3 Thực nghiệm và Kết quả	12
3.1 Bộ dữ liệu	12
3.1.1 Phân tích toàn bộ tập dữ liệu	13

3.1.2	Phân tích theo từng chủng tộc	15
3.2	Thiết lập thực nghiệm	18
3.2.1	Môi trường phần cứng	18
3.2.2	Tiền xử lý dữ liệu	18
3.2.3	Trích xuất đặc trưng	19
3.2.4	Cấu hình mô hình và Tham số huấn luyện	20
3.2.5	Tiêu chí đánh giá	20
3.3	Kết quả thực nghiệm	21
3.3.1	So sánh hiệu năng các phương pháp trích xuất đặc trưng	21
3.4	Tổng kết chương	23
4	Thảo luận	24
4.1	Phân tích lỗi sai	24
4.1.1	Sai số theo nhóm tuổi	24
4.1.2	Sai số theo giới tính	25
4.1.3	Sai số theo chủng tộc	25
4.1.4	Đánh giá phương pháp huấn luyện chung và riêng rẽ .	27
4.2	Phân tích khả năng giảm chiều dữ liệu	29
4.3	Tổng kết chương	31
5	Kết luận và Hướng phát triển	32
5.1	Kết luận	32
5.2	Hướng phát triển	33

Danh sách hình vẽ

2.1	Sơ đồ pipeline xử lý: ảnh khuôn mặt $\rightarrow$ tiền xử lý $\rightarrow$ trích rút đặc trưng $\rightarrow$ giảm chiều dữ liệu (tùy chọn) $\rightarrow$ hồi quy tuổi.	4
3.1	Phân phối độ tuổi toàn bộ tập dữ liệu UTKFace.	14
3.2	Phân bố số lượng ảnh theo nhóm tuổi.	14
3.3	Tỷ lệ giới tính trong toàn bộ tập dữ liệu.	15
3.4	Đường cong mật độ độ tuổi theo giới tính.	16
3.5	Phân bố số lượng mẫu theo chủng tộc.	16
3.6	Cấu trúc giới tính bên trong từng nhóm chủng tộc.	17
3.7	Mật độ và phân tán độ tuổi trên từng nhóm chủng tộc.	17
3.8	Biểu đồ so sánh RMSE và MAE của 3 phương pháp trích xuất đặc trưng với 3 mô hình học máy.	22
3.9	Biểu đồ phân tán (Scatter Plot) giữa tuổi thực tế và tuổi dự đoán của mô hình HOG + MLP.	23
4.1	Sai số dự đoán (MAE) phân loại theo từng nhóm tuổi.	24
4.2	Sai số dự đoán (MAE) phân loại theo giới tính.	25
4.3	Sai số dự đoán (MAE) trung bình theo từng chủng tộc.	26
4.4	Mật độ và phân tán của sai số dự đoán theo từng chủng tộc.	26
4.6	So sánh MAE khi huấn luyện chung toàn bộ dữ liệu và huấn luyện riêng rẽ cho từng chủng tộc.	27
4.5	Phân tích MAE theo nhóm tuổi cho từng chủng tộc.	28
4.7	So sánh sai số RMSE theo số lượng thành phần chính (PCA) trên 3 mô hình.	30

Danh sách bảng

3.1	Thống kê mô tả độ tuổi toàn cục trên tập UTKFace.	13
3.2	Kết quả đánh giá các cấu hình đặc trưng và mô hình.	21
4.1	Đánh giá RMSE của các mô hình theo mức độ giảm chiều PCA.	29

Danh sách từ viết tắt

- CNN: Convolutional Neural Network.
- DoG: Difference of Gaussians.
- GAN: Generative Adversarial Network.
- HOG: Histogram of Oriented Gradients.
- LBP: Local Binary Pattern.
- LoG: Laplacian of Gaussian.
- MAE: Mean Absolute Error.
- MLP: Multi-Layer Perceptron.
- MSE: Mean Squared Error.
- PCA: Principal Component Analysis.
- ReLU: Rectified Linear Unit.
- RF: Random Forest.
- RMSE: Root Mean Square Error.
- SIFT: Scale-Invariant Feature Transform.
- SMOTE: Synthetic Minority Over-sampling Technique.
- SVM: Support Vector Machine.
- SVR: Support Vector Regression.

Chương 1. Mở đầu

1.1 Đặt vấn đề

Hồi quy tuổi từ khuôn mặt là một bài toán quan trọng trong thị giác máy tính vì nó hỗ trợ nhiều ứng dụng thực tế như quảng cáo theo độ tuổi, phân tích nhân khẩu học, kiểm soát truy cập và cá nhân hoá trải nghiệm người dùng. Một số hướng tiếp cận trong tài liệu cho thấy việc dự đoán tuổi từ ảnh khuôn mặt là khả thi, nhưng vẫn còn khó khăn do sự thay đổi về biểu cảm, góc chụp, ánh sáng và khác biệt cá nhân trong quá trình lão hoá [1, 2].

Việc xây dựng mô hình hồi quy tuổi chính xác đòi hỏi trích xuất đặc trưng khuôn mặt phù hợp và thiết kế mô hình có khả năng biểu diễn mối quan hệ phi tuyến giữa đặc trưng và tuổi thực. Ngoài ra, dữ liệu huấn luyện thường bị lệch theo phân bố tuổi hoặc chứa nhân không hoàn toàn chính xác, khiến khả năng tổng quát hoá của mô hình bị ảnh hưởng đáng kể [3, 1].

1.2 Giới thiệu bài toán

Đề tài này là xây dựng một phương pháp ước lượng tuổi dựa trên ảnh khuôn mặt, với đầu ra là một giá trị tuổi liên tục. Dữ liệu đầu vào là ảnh khuôn mặt đã được tiền xử lý, còn đầu ra cần phản ánh tuổi thực của từng cá nhân thay vì chỉ phân loại theo các nhóm tuổi rời rạc.

Yêu cầu chính của bài toán là bảo đảm phương pháp dự đoán ổn định trước các biến đổi về góc chụp, biểu cảm, ánh sáng và sự khác biệt giữa các cá nhân. Đồng thời, kết quả cần được đánh giá bằng các thước đo định lượng cụ thể để xác định mức độ sai lệch giữa tuổi dự đoán và tuổi thật.

Bài toán này có ý nghĩa thực tiễn trong nhiều ứng dụng thị giác máy tính và phân tích người dùng, đồng thời đòi hỏi xem xét độ tin cậy, tính công bằng và quyền riêng tư khi sử dụng dữ liệu khuôn mặt.

1.3 Mục tiêu

Mục tiêu tổng quát của đề tài là xây dựng một giải pháp ước lượng tuổi từ ảnh khuôn mặt và đánh giá khả năng tổng quát hoá của nó trên nhiều điều kiện chụp khác nhau.

Mục tiêu cụ thể:


- Thiết kế quy trình tiền xử lý và trích xuất thông tin khuôn mặt phù hợp cho nhiệm vụ ước lượng tuổi.
- Xây dựng mô hình dự đoán tuổi liên tục và lựa chọn tiêu chí đánh giá phù hợp cho bài toán hồi quy.
- Lựa chọn và chuẩn hoá bộ dữ liệu phù hợp cho bài toán ước lượng tuổi.
- Đánh giá phương pháp bằng các chỉ số như MAE (Mean Absolute Error) và RMSE trên các bộ dữ liệu chuẩn.
- Thảo luận hạn chế của phương pháp.

1.4 Tổng kết chương

Chương mở đầu đã trình bày tổng quan về bài toán hồi quy tuổi từ ảnh khuôn mặt, bao gồm bối cảnh thực tế và các khó khăn gặp phải. Từ đó, mục tiêu của đề tài được xác định rõ ràng là xây dựng một hệ thống hoàn chỉnh từ tiền xử lý, trích xuất đặc trưng đến thiết kế mô hình học máy để dự đoán tuổi. Những mục tiêu này là định hướng quan trọng để tiến hành các bước nghiên cứu và thực nghiệm ở các chương tiếp theo.

Chương 2. Cơ sở lí thuyết

Chương này trình bày các kiến thức nền tảng cần thiết cho bài toán ước lượng tuổi từ ảnh khuôn mặt. Nội dung tập trung vào các phương pháp trích xuất đặc trưng, giảm chiều dữ liệu và các mô hình hồi quy thường được sử dụng để dự đoán tuổi từ đặc trưng ảnh.



Hình 2.1: Sơ đồ pipeline xử lý: ảnh khuôn mặt $\rightarrow$ tiền xử lý $\rightarrow$ trích rút đặc trưng $\rightarrow$ giảm chiều dữ liệu (tùy chọn) $\rightarrow$ hồi quy tuổi.

2.1 Các phương pháp trích xuất đặc trưng

Trích xuất đặc trưng là bước quan trọng nhằm chuyển đổi ảnh khuôn mặt từ dữ liệu thô sang biểu diễn phù hợp hơn cho mô hình học máy. Một bộ đặc trưng hiệu quả cần bảo toàn thông tin quan trọng về hình dạng, biên, kết cấu và các vùng biến thiên trên khuôn mặt, đồng thời hạn chế ảnh hưởng của nhiễu và biến đổi chiếu sáng.

2.1.1 Histogram of Oriented Gradients (HOG)

Histogram of Oriented Gradients là phương pháp mô tả phân bố hướng gradient trong từng vùng nhỏ của ảnh. Ý tưởng chính của HOG là chia ảnh thành nhiều ô (cell), tính gradient tại từng điểm ảnh, sau đó phân bố hướng gradient vào các bin của histogram định hướng (orientation histogram). Các histogram này được chuẩn hoá theo từng khối (block) để giảm ảnh hưởng của thay đổi độ sáng và tương phản.

Về mặt tính toán, đặt $I(x, y)$ là giá trị cường độ pixel tại vị trí (x, y) . Gradient theo phương ngang và dọc được lấy bằng tích chập với các toán tử đạo hàm (ví dụ Sobel):

$$G_x = I * \nabla_x, \quad G_y = I * \nabla_y.$$

Trong đó ∇_x, ∇_y là các toán tử theo hai hướng x, y . Đặt độ lớn gradient là $m(x, y)$, khi đó:

$$m(x, y) = \sqrt{G_x(x, y)^2 + G_y(x, y)^2}.$$

Hướng gradient được tính bởi:

$$\theta(x, y) = \tan^{-1} \left(\frac{G_y(x, y)}{G_x(x, y)} \right).$$

Mỗi pixel đóng góp vào các bin định hướng của histogram theo trọng số là độ lớn gradient $m(x, y)$. Với vector histogram khối h , bước chuẩn hoá phổ biến là L2-Hys:

$$\hat{h} = \frac{h}{\sqrt{\|h\|_2^2 + \varepsilon^2}}.$$

Về số chiều, với ảnh xám $I \in \mathbb{R}^{H \times W}$ thì $G_x, G_y, m, \theta \in \mathbb{R}^{H \times W}$; vector đặc trưng HOG cuối cùng được ký hiệu $x_{\text{HOG}} \in \mathbb{R}^{d_{\text{HOG}}}$. Mô tả HOG chuẩn và hiệu quả của nó cho nhận dạng đối tượng được trình bày trong [4].

HOG thường được sử dụng để biểu diễn cấu trúc biên và hình dạng tổng thể của khuôn mặt, do đặc trưng này nhạy với các chuyển tiếp cường độ cục bộ. Phương pháp này có tính ổn định tương đối trước biến đổi cường độ và sinh ra biểu diễn đặc trưng có khả năng phân biệt tương đối tốt. Tuy nhiên, HOG phụ thuộc đáng kể vào căn chỉnh ảnh đầu vào và có thể không mô tả đầy đủ các chi tiết kết cấu tinh vi trên khuôn mặt.

2.1.2 Local Binary Pattern (LBP)

Local Binary Pattern là phương pháp mô tả kết cấu ảnh bằng cách so sánh giá trị điểm ảnh trung tâm với các điểm lân cận. Nếu điểm lân cận lớn hơn hoặc bằng điểm trung tâm thì gán giá trị 1, ngược lại gán 0. Chuỗi nhị phân thu được sẽ được chuyển thành một mã số để biểu diễn đặc trưng vùng ảnh.

Định nghĩa LBP tổng quát với P điểm lân cận trên vòng tròn bán kính R :

$$\text{LBP}_{P,R} = \sum_{p=0}^{P-1} s(g_p - g_c) 2^p,$$

trong đó g_c là mức xám điểm trung tâm, g_p là mức xám điểm lân cận thứ p ,

và

$$s(t) = \begin{cases} 1, & t \geq 0 \\ 0, & t < 0. \end{cases}$$

Histogram các mã LBP theo từng vùng sau đó được nối lại thành vector đặc trưng toàn ảnh. Công thức và các biến thể "uniform patterns" được mô tả trong [5]. Về số chiều, mỗi mã LBP thuộc tập $\{0, \dots, 2^P - 1\}$, histogram của một vùng thuộc $\mathbb{R}^{2^P}$; khi nối các vùng, đặc trưng toàn ảnh được ký hiệu $x_{\text{LBP}} \in \mathbb{R}^{d_{\text{LBP}}}$.

LBP khai thác hiệu quả thông tin kết cấu cục bộ trên khuôn mặt, đặc biệt tại các vùng như trán, mắt, má và nếp nhăn. Phương pháp này có độ phức tạp tính toán thấp và ít nhạy với các biến đổi đơn điệu về độ sáng. Hạn chế của LBP là có thể nhạy với nhiễu cục bộ và không mô tả tốt quan hệ hình học ở quy mô lớn.

2.1.3 Scale-Invariant Feature Transform (SIFT)

Scale-Invariant Feature Transform là phương pháp phát hiện và mô tả các điểm đặc trưng nổi bật trong ảnh. SIFT xây dựng không gian tỉ lệ bằng cách làm trơn ảnh với nhân Gaussian, sau đó tìm điểm cực trị trên ảnh sai khác Gaussian (Difference of Gaussians) để xác định keypoint bất biến theo tỉ lệ [6].

Ảnh ở mức tỉ lệ σ được tính bởi:

$$L(x, y, \sigma) = G(x, y, \sigma) * I(x, y),$$

trong đó nhân Gaussian được viết là:

$$G(x, y, \sigma) = \frac{1}{2\pi\sigma^2} \exp\left(-\frac{x^2 + y^2}{2\sigma^2}\right).$$

Ảnh sai khác Gaussian (Difference of Gaussians) giữa hai mức tỉ lệ liên tiếp là:

$$D(x, y, \sigma) = L(x, y, k\sigma) - L(x, y, \sigma).$$

Toán tử DoG được dùng để xấp xỉ Laplacian của Gaussian (LoG):

$$\nabla^2 I = \frac{\partial^2 I}{\partial x^2} + \frac{\partial^2 I}{\partial y^2}.$$

Cụ thể, DoG $D(x, y, \sigma)$ xấp xỉ $\sigma^2 \nabla^2 G(x, y, \sigma) * I(x, y)$ với độ chính xác cao, nhưng tính toán nhanh hơn nhiều. Do đó, tìm cực trị trên DoG sẽ xác định điểm ổn định theo lý thuyết của LoG, nhưng với chi phí tính toán thấp hơn.

Sau khi định vị keypoint, gradient cục bộ tại vùng lân cận được tính bởi:

$$G_x = I * \nabla_x, \quad G_y = I * \nabla_y,$$

$$m(x, y) = \sqrt{G_x^2 + G_y^2}, \quad \theta(x, y) = \tan^{-1} \left(\frac{G_y}{G_x} \right).$$

Vùng xung quanh keypoint được chia thành lưới 4×4 ô, mỗi ô tạo một histogram gồm 8 hướng. Ghép 16 histogram này lại sẽ thu được descriptor 128 chiều. Về số chiều, $L(\cdot, \cdot, \sigma), D(\cdot, \cdot, \sigma) \in \mathbb{R}^{H \times W}$ và mỗi descriptor cục bộ $s_j \in \mathbb{R}^{128}$; sau bước gom/pooling về độ dài cố định, đặc trưng đầu vào mô hình hồi quy được ký hiệu $x_{\text{SIFT}} \in \mathbb{R}^{d_{\text{SIFT}}}$.

SIFT có tính bất biến tương đối đối với thay đổi tỉ lệ và phép quay, đồng thời ổn định một phần trước biến thiên chiếu sáng. Trong bài toán ảnh khuôn mặt, SIFT có thể được sử dụng để phát hiện các điểm đặc trưng như mắt, mũi, miệng hoặc các vùng có độ biến thiên cao. Tuy nhiên, việc trích xuất SIFT thường có chi phí tính toán cao hơn HOG và LBP, đồng thời số lượng điểm đặc trưng có thể thay đổi giữa các ảnh, gây khó khăn khi xây dựng biểu diễn cố định cho mô hình hồi quy.

2.2 Giảm chiều dữ liệu

Sau khi trích xuất đặc trưng, vector đặc trưng thường có số chiều lớn và chứa nhiều thành phần dư thừa. Giảm chiều dữ liệu giúp rút gọn không gian đặc trưng, giảm chi phí tính toán và có thể cải thiện khả năng tổng quát hoá của mô hình.

2.2.1 Principal Component Analysis (PCA)

Principal Component Analysis là phương pháp giảm chiều tuyến tính bằng cách tìm các trục mới sao cho dữ liệu được biểu diễn với phương sai lớn nhất trên các trục đầu tiên. PCA biến đổi vector đặc trưng ban đầu sang một không gian mới gồm các thành phần chính, trong đó mỗi thành phần là một tổ hợp tuyến tính của các biến gốc.

Với ma trận dữ liệu đã chuẩn hoá trung bình $X \in \mathbb{R}^{n \times d}$, ma trận hiệp phương sai:

$$C = \frac{1}{n-1} X^\top X.$$

Các thành phần chính thu được từ bài toán trị riêng:

$$Cu_i = \lambda_i u_i, \quad \lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_d.$$

Giữ k vector riêng đầu tiên $U_k = [u_1, \dots, u_k]$, phép chiếu đặc trưng là:

$$z = U_k^\top (x - \mu).$$

Trong đó $x, \mu \in \mathbb{R}^d$, $U_k \in \mathbb{R}^{d \times k}$ và $z \in \mathbb{R}^k$. Nội dung nền tảng và cách chọn số thành phần chính được trình bày trong [7].

Trong thực tế, PCA thường được dùng để nén dữ liệu đặc trưng trước khi đưa vào mô hình hồi quy. Lợi ích của PCA là giảm số chiều, loại bỏ một phần nhiễu và giảm hiện tượng đa cộng tuyến giữa các biến. Tuy nhiên, PCA có hạn chế là làm mất một phần thông tin gốc và chỉ phù hợp với các quan hệ tuyến tính.

2.3 Các mô hình hồi quy

Sau khi có đặc trưng ảnh, bài toán ước lượng tuổi được mô hình hoá như một bài toán hồi quy, trong đó đầu ra là một giá trị liên tục. Các mô hình hồi quy được sử dụng để học mối quan hệ giữa đặc trưng khuôn mặt và tuổi thực.

2.3.1 Support Vector Regression (SVR)

Support Vector Regression là biến thể của Support Vector Machine dùng cho bài toán hồi quy. SVR cố gắng tìm một hàm dự đoán sao cho sai số nằm trong một ngưỡng cho phép, đồng thời vẫn giữ cho mô hình đơn giản nhất có thể.

Dạng tối ưu hoá chuẩn của ε -SVR:

$$\min_{w,b,\xi,\xi^*} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n (\xi_i + \xi_i^*)$$

với các ràng buộc

$$\begin{aligned} y_i - (w^\top \phi(x_i) + b) &\leq \varepsilon + \xi_i, \\ (w^\top \phi(x_i) + b) - y_i &\leq \varepsilon + \xi_i^*, \\ \xi_i, \xi_i^* &\geq 0. \end{aligned}$$

Trong không gian kernel, hàm dự đoán:

$$f(x) = \sum_{i=1}^n (\alpha_i - \alpha_i^*) K(x_i, x) + b.$$

Về số chiều, mỗi mẫu đặc trưng $x_i \in \mathbb{R}^d$, đầu ra $y_i \in \mathbb{R}$, vector tham số tuyến tính $w \in \mathbb{R}^{d_\phi}$ trong không gian đặc trưng $\phi(x) \in \mathbb{R}^{d_\phi}$. Các kết quả gốc về SVR và bài toán hồi quy SVM được trình bày trong [8].

SVR hoạt động hiệu quả trên dữ liệu có số chiều vừa phải và có thể kết hợp với các hàm kernel để mô hình hoá quan hệ phi tuyến. Trong bài toán ước lượng tuổi, SVR thường được xem như một mô hình tham chiếu do khả năng làm việc tốt với vector đặc trưng đã trích xuất. Tuy nhiên, SVR có thể khó mở rộng khi dữ liệu quá lớn.

2.3.2 Random Forest

Random Forest là mô hình tổ hợp gồm nhiều cây quyết định được huấn luyện trên các tập con khác nhau của dữ liệu và đặc trưng. Với bài toán hồi quy, đầu ra của Random Forest là giá trị trung bình từ các cây thành phần.

Nếu rừng có T cây hồi quy $f_t(x)$, dự đoán cuối cùng là:

$$\hat{y}(x) = \frac{1}{T} \sum_{t=1}^T f_t(x).$$

Mỗi cây thường được học từ bootstrap sample và tách nhánh theo tiêu chí giảm phương sai (hoặc MSE), ví dụ:

$$\text{MSE}(S) = \frac{1}{|S|} \sum_{(x_i, y_i) \in S} (y_i - \bar{y}_S)^2.$$

Về số chiều, $x \in \mathbb{R}^d$, $y \in \mathbb{R}$ và mỗi cây hồi quy là ánh xạ $f_t : \mathbb{R}^d \rightarrow \mathbb{R}$. Kết hợp bagging và lựa chọn ngẫu nhiên tập con đặc trưng giúp giảm phương sai và tăng khả năng tổng quát hoá của mô hình [9].

Random Forest có tính ổn định cao hơn một cây quyết định đơn lẻ, ít bị quá khớp và có khả năng xử lý quan hệ phi tuyến giữa đặc trưng và đầu ra. Tuy vậy, mô hình này có thể không khai thác đầy đủ cấu trúc phức tạp trong dữ liệu ảnh và phụ thuộc nhiều vào chất lượng đặc trưng đầu vào.

2.3.3 Multi-Layer Perceptron Regression

Multi-Layer Perceptron Regression là mô hình mạng nơ-ron nhiều lớp được sử dụng cho bài toán dự đoán giá trị liên tục. Mô hình gồm các lớp ẩn với hàm kích hoạt phi tuyến và một lớp đầu ra cho giá trị hồi quy.

Đặt $a^{(0)} = x \in \mathbb{R}^{d_0}$, với mỗi lớp ℓ có $W^{(\ell)} \in \mathbb{R}^{d_\ell \times d_{\ell-1}}$, $b^{(\ell)} \in \mathbb{R}^{d_\ell}$, và $f^{(\ell)}, a^{(\ell)}, \delta^{(\ell)} \in \mathbb{R}^{d_\ell}$. Ở đầu ra hồi quy một biến, $\hat{y}, y \in \mathbb{R}$.

Feedforward

$$\begin{aligned} f^{(\ell)}(x) &:= W^{(\ell)} a^{(\ell-1)} + b^{(\ell)}, \\ a^{(\ell)} &:= \max(0, f^{(\ell)}(x)), \quad \ell = 1, \dots, L-1, \\ f^{(L)}(x) &:= W^{(L)} a^{(L-1)} + b^{(L)}, \\ \hat{y} &:= f^{(L)}(x). \end{aligned}$$

Hàm mất mát

$$\mathcal{L}_{\text{MSE}} := \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2.$$

Backpropagation

$$\begin{aligned} \delta^{(L)} &:= \frac{\partial \mathcal{L}}{\partial f^{(L)}} = \frac{2}{n} (\hat{y} - y), \\ \delta^{(\ell)} &:= \frac{\partial \mathcal{L}}{\partial f^{(\ell)}} = \left(W^{(\ell+1)} \right)^\top \delta^{(\ell+1)} \odot \mathbf{1}_{f^{(\ell)} > 0}, \quad \ell = L-1, \dots, 1, \\ \frac{\partial \mathcal{L}}{\partial W^{(\ell)}} &:= \delta^{(\ell)} \left(a^{(\ell-1)} \right)^\top, \\ \frac{\partial \mathcal{L}}{\partial b^{(\ell)}} &:= \delta^{(\ell)}. \end{aligned}$$

Cập nhật tham số

$$\begin{aligned} W^{(\ell)} &:= W^{(\ell)} - \eta \frac{\partial \mathcal{L}}{\partial W^{(\ell)}}, \\ b^{(\ell)} &:= b^{(\ell)} - \eta \frac{\partial \mathcal{L}}{\partial b^{(\ell)}}. \end{aligned}$$

Trình bày nền tảng về MLP và huấn luyện mạng nơ-ron có thể xem trong [10].

MLP Regression có khả năng học các quan hệ phi tuyến giữa đặc trưng khuôn mặt và tuổi, đặc biệt khi đầu vào đã được rút gọn và chuẩn hoá tốt. Mô hình này linh hoạt hơn các phương pháp tuyến tính nhưng cần điều chỉnh số lớp, số nút và tham số huấn luyện để tránh quá khớp.

2.4 Tổng kết chương

Các phương pháp trích xuất đặc trưng như HOG, LBP và SIFT giúp chuyển đổi ảnh khuôn mặt sang dạng biểu diễn phù hợp hơn cho mô hình học máy. PCA hỗ trợ giảm chiều và nén thông tin, còn các mô hình hồi quy như SVR, Random Forest và MLP Regression là những lựa chọn phổ biến để dự đoán tuổi từ đặc trưng đã rút trích. Đây là cơ sở để xây dựng và so sánh các phương pháp trong những chương tiếp theo.

Chương 3. Thực nghiệm và Kết quả

Chương này trình bày chi tiết về toàn bộ quá trình thực nghiệm nhằm đánh giá hiệu năng của các phương pháp đề xuất. Nội dung chương bao gồm phân tích đặc điểm bộ dữ liệu UTKFace, mô tả quy trình thiết lập môi trường và cấu hình tham số cho các mô hình học máy. Cuối cùng, các kết quả dự đoán tuổi thực tế sẽ được tổng hợp, trực quan hóa và so sánh dựa trên các độ đo sai số chuẩn (RMSE, MAE) để từ đó lựa chọn ra mô hình tối ưu nhất cho bài toán.

3.1 Bộ dữ liệu

Trong tiểu luận này, tập dữ liệu sử dụng cho bài toán hồi quy tuổi là UTKFace [11, 12], một bộ ảnh khuôn mặt công khai được lấy từ Kaggle. Tập dữ liệu này chứa tổng cộng 23.705 ảnh, mỗi ảnh đi kèm nhãn được mã hóa trực tiếp trong tên tệp theo mẫu:

`[age]_[gender]_[race]_[date&time].jpg`

Trong đó:

- **age** là tuổi của đối tượng, được biểu diễn bởi một số nguyên từ 0 đến 116.
- **gender** nhận giá trị 0 cho nam và 1 cho nữ.
- **race** nhận giá trị từ 0 đến 4, tương ứng với White, Black, Asian, Indian và Others.
- **date&time** là dấu thời gian thu thập ảnh theo định dạng `yyyymmddHHMMSSFFF`.

Việc nhãn được nhúng sẵn trong tên ảnh giúp quá trình xây dựng tập dữ liệu thuận tiện hơn vì không cần gán nhãn thủ công. Tuy nhiên, cách tổ chức này cũng đòi hỏi bước tiền xử lý cẩn thận để đọc đúng nhãn, loại bỏ các tệp lỗi và kiểm tra những mẫu có thông tin bất thường. Trong bài toán này, nhãn tuổi là đầu ra chính cần dự đoán; còn giới tính và chủng tộc được dùng

như thông tin bổ sung để phân tích phân bố dữ liệu, đánh giá mức độ phụ thuộc của dữ liệu vào hai yếu tố này dựa trên đặc điểm ảnh, và xem xét ảnh hưởng của chúng đến kết quả dự đoán tuổi.

3.1.1 Phân tích toàn bộ tập dữ liệu

Bảng 3.1 tóm tắt nhanh các thống kê mô tả của biến tuổi trên toàn bộ 23.705 ảnh. Có thể thấy tuổi trung bình là 33.30, trung vị là 29 và độ lệch chuẩn xấp xỉ 19.89, cho thấy phân bố tuổi có độ phân tán lớn.


Bảng 3.1: Thống kê mô tả độ tuổi toàn cục trên tập UTKFace.

Count	Mean	Std	Min	25%	50% (Median)	75%	Max
23705	33.300907	19.885708	1	23	29	45	116


Biểu đồ ở Hình 3.1 cho thấy phân bố tuổi của toàn bộ tập dữ liệu không đồng đều. Phần lớn ảnh tập trung trong khoảng 21–40 tuổi, với đỉnh phân bố rơi vào vùng 25–30 tuổi. Ngoài cụm chính này, tập dữ liệu vẫn có một lượng ảnh đáng kể ở nhóm trẻ nhỏ từ 0–5 tuổi và một đuôi phân bố kéo dài về phía các độ tuổi lớn hơn 60.

Sự lệch phân bố này có ý nghĩa quan trọng đối với bài toán hồi quy tuổi. Nếu mô hình được huấn luyện trực tiếp trên dữ liệu gốc mà không có cơ chế cân bằng hoặc tăng cường dữ liệu, mô hình có xu hướng học tốt hơn ở các nhóm tuổi xuất hiện nhiều, đặc biệt là nhóm người trưởng thành trẻ, trong khi dễ sai lệch hơn ở các nhóm rất trẻ hoặc rất già.

Phân bố theo nhóm tuổi. Để nhìn rõ hơn mức độ mất cân bằng dữ liệu, tuổi được gom thành các nhóm rời rạc. Hình 3.2 cho thấy nhóm 21–30 tuổi chiếm ưu thế rất lớn với khoảng 7.7 nghìn ảnh, tiếp theo là nhóm 31–40 tuổi với khoảng 4.3 nghìn ảnh. Nhóm 0–5 tuổi cũng có số lượng tương đối lớn, trong khi nhóm 80+ chỉ chiếm một phần rất nhỏ của tập dữ liệu.



Hình 3.1: Phân phối độ tuổi toàn bộ tập dữ liệu UTKFace.




Hình 3.2: Phân bố số lượng ảnh theo nhóm tuổi.

Phân bố giới tính. Hình 3.3 cho thấy tập dữ liệu khá cân bằng về giới tính, với nam chiếm khoảng 52.3% và nữ chiếm khoảng 47.7%.

Tuy nhiên, đường mật độ trong Hình 3.4 chỉ ra rằng phân bố tuổi giữa hai


giới không hoàn toàn giống nhau. Nhóm nữ tập trung mạnh hơn quanh vùng 20–35 tuổi, trong khi nhóm nam có độ trải rộng lớn hơn và kéo dài nhiều hơn về các độ tuổi cao. Điều này cho thấy nếu mô hình mắc lỗi khác nhau giữa nam và nữ, nguyên nhân không chỉ đến từ số lượng ảnh mà còn đến từ hình thái dữ liệu và cấu trúc độ tuổi đi kèm mỗi nhóm.




Hình 3.3: Tỷ lệ giới tính trong toàn bộ tập dữ liệu.

3.1.2 Phân tích theo từng chủng tộc


Phân bố theo chủng tộc trong UTKFace cũng thể hiện sự mất cân bằng khá rõ. Hình 3.5 cho thấy nhóm White chiếm tỷ lệ lớn nhất với khoảng 42.5%, tiếp theo là Black (19.1%), Indian (16.8%), Asian (14.5%) và Others (7.1%). Khi nhìn theo giới tính ở Hình 3.6, có thể thấy White vẫn là nhóm áp đảo ở cả nam lẫn nữ, trong khi các nhóm còn lại có số lượng nhỏ hơn nhiều.



Hình 3.4: Đường cong mật độ độ tuổi theo giới tính.




Hình 3.5: Phân bố số lượng mẫu theo chủng tộc.



Hình 3.6: Cấu trúc giới tính bên trong từng nhóm chủng tộc.

Tương quan giữa tuổi và chủng tộc. Biểu đồ violin ở Hình 3.7 cho thấy độ tuổi của từng nhóm chủng tộc có sự phân tán khác nhau. Nhóm White có dải tuổi rộng nhất, bao phủ cả người trẻ, trung niên và cao tuổi. Các nhóm Asian và Others lại tập trung nhiều hơn ở các độ tuổi trẻ và trung niên, trong khi số mẫu ở độ tuổi rất cao tương đối ít. Điều này phản ánh không chỉ sự khác biệt về phân bố dữ liệu mà còn cho thấy một số vùng tuổi - chủng tộc có mật độ mẫu thấp hơn đáng kể so với phần còn lại của tập dữ liệu.



Hình 3.7: Mật độ và phân tán độ tuổi trên từng nhóm chủng tộc.

Từ các biểu đồ trên có thể rút ra các nhận xét chính. Thứ nhất, UTKFace là bộ dữ liệu đủ lớn và có nhãn phong phú, phù hợp cho bài toán hồi quy tuổi. Thứ hai, phân bố tuổi không đồng đều, đặc biệt tập trung mạnh ở nhóm 21–40 tuổi, nên mô hình dễ thiên lệch về vùng tuổi này. Thứ ba, dữ liệu tồn tại mất cân bằng theo chủng tộc và sự khác biệt về phân bố tuổi giữa các nhóm nhân khẩu học, vì vậy cần đánh giá mô hình theo nhiều góc nhìn khác nhau.

3.2 Thiết lập thực nghiệm

Phần này trình bày chi tiết về quy trình và các điều kiện được thiết lập để tiến hành huấn luyện và đánh giá mô hình. Các nội dung chính bao gồm: cấu hình môi trường phần cứng máy tính, các bước tiền xử lý và chia tách tập dữ liệu, phương pháp trích xuất đặc trưng hình ảnh (HOG, LBP, SIFT), thiết lập tham số cho các mô hình học máy (SVR, Random Forest, MLP) và cuối cùng là các tiêu chí đánh giá hiệu năng (RMSE, MAE).

3.2.1 Môi trường phần cứng

Các thí nghiệm được thực hiện trên máy tính cá nhân với cấu hình phần cứng như sau:

- **CPU:** AMD Ryzen AI 7 350 (8 CPUs - 16 threads), 2.0GHz
- **RAM:** 32 GB

3.2.2 Tiền xử lý dữ liệu

Dữ liệu từ UTKFace được xử lý theo hai bước chính: chia tập và tiền xử lý ảnh.

Chia tập dữ liệu. Để đảm bảo tính cân bằng giữa các nhóm nhân khẩu học, tập dữ liệu được chia thành train (80%) và test (20%) bằng stratified splitting. Cụ thể, một khóa stratification được tạo bằng cách kết hợp chủng tộc (race) và nhóm tuổi (age_group), đảm bảo mỗi tổ hợp race-age_group xuất hiện ở cả tập train lẫn test với tỷ lệ tương đương. Trước khi chia, những nhóm có quá ít mẫu (ít hơn 2 ảnh) được loại bỏ để tránh lỗi stratification.

Các chỉ số tập train và test được lưu để sử dụng lại trong các thí nghiệm.

Tiền xử lý ảnh. Mỗi ảnh đầu vào trải qua quy trình tiền xử lý như sau:

1. **Đọc ảnh:** Sử dụng OpenCV để đọc ảnh từ đường dẫn. Nếu đọc thất bại, trả về ảnh đen kích thước chuẩn hóa.
2. **Khử nhiễu:** Áp dụng Gaussian Blur với kernel 3×3 để giảm nhiễu và làm mượt ảnh.
3. **Chuẩn hóa kích thước:** Resize ảnh về kích thước chuẩn định (128×128) bằng phương pháp INTER_AREA.
4. **Chuyển đổi không gian màu:** Ảnh được chuyển từ BGR (mặc định OpenCV) sang Grayscale.

Sau tiền xử lý, ảnh được đưa qua bước trích xuất đặc trưng trước khi đưa vào huấn luyện mô hình.

3.2.3 Trích xuất đặc trưng

Thay vì sử dụng trực tiếp toàn bộ giá trị pixel của ảnh làm đầu vào, các đặc trưng cục bộ được trích xuất nhằm nâng cao khả năng biểu diễn thông tin và độ mạnh mẽ của mô hình. Có 3 phương pháp trích xuất đặc trưng được cài đặt và so sánh:

- **HOG (Histogram of Oriented Gradients):** Trích xuất đặc trưng định hướng gradient với số lượng hướng là 9. Cấu hình được đặt là 8×8 pixels cho mỗi cell và 2×2 cells cho mỗi block. Quá trình chuẩn hóa block sử dụng chuẩn L2-Hys.
- **LBP (Local Binary Pattern):** Trích xuất đặc trưng kết cấu cục bộ bằng phương pháp LBP uniform, với bán kính lân cận $R = 1$ và số điểm mẫu $P = 8$. Vector đặc trưng cuối cùng là một biểu đồ tần suất (histogram) đã được chuẩn hóa L1 của các giá trị LBP trên toàn ảnh.
- **SIFT (Scale-Invariant Feature Transform):** Sử dụng thuật toán SIFT để phát hiện và trích xuất các điểm đặc trưng cục bộ. Vector đặc trưng đại diện cho mỗi ảnh được tính bằng trung bình (mean) của toàn bộ các SIFT descriptors được tìm thấy trong ảnh đó.

3.2.4 Cấu hình mô hình và Tham số huấn luyện

Dữ liệu đặc trưng thu được từ các phương pháp trên sẽ được dùng để huấn luyện độc lập trên 3 mô hình hồi quy học máy khác nhau:

- **SVR (Support Vector Regression):** Sử dụng nhân (kernel) RBF, với tham số phạt $C = 1.0$. Dữ liệu đầu vào được chuẩn hóa bằng `StandardScaler` trước khi đi vào mô hình SVR.
- **Random Forest Regressor:** Mô hình học máy dạng tập hợp (ensemble) cấu tạo từ 100 cây quyết định (`n_estimators=100`). Độ sâu tối đa của mỗi cây được giới hạn ở mức 10 (`max_depth=10`). Mô hình chạy đa luồng (`n_jobs=-1`) để tăng tốc xử lý.
- **MLP (Multi-layer Perceptron):** Mạng nơ-ron truyền thẳng gồm 2 tầng ẩn với số lượng nơ-ron lần lượt là 256 và 128. Mô hình sử dụng hàm kích hoạt ReLU, thuật toán tối ưu hóa Adam, và hệ số chuẩn hóa regularization $\alpha = 0.001$. Quá trình huấn luyện kéo dài tối đa 200 epochs. Tương tự SVR, dữ liệu đi vào MLP cũng được chuẩn hóa bằng `StandardScaler`.

3.2.5 Tiêu chí đánh giá

Hiệu năng dự đoán tuổi của các mô hình được đo lường thông qua 2 độ đo chính:

- **RMSE (Root Mean Square Error):** Căn bậc hai của sai lệch bình phương trung bình, phản ánh độ lệch chuẩn của phần dư. Việc bình phương sai số trước khi tính trung bình giúp RMSE phạt nặng hơn những dự đoán có sai số lớn. Công thức tính:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

- **MAE (Mean Absolute Error):** Độ sai lệch tuyệt đối trung bình giữa tuổi dự đoán và tuổi thực tế. MAE mang ý nghĩa trực quan cao, cho

biết trung bình mô hình dự đoán sai lệch bao nhiêu tuổi so với nhãn gốc.
Công thức tính:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

Trong đó, n là tổng số mẫu dữ liệu đánh giá, y_i là tuổi thực tế (ground truth) và $\hat{y}_i$ là tuổi do mô hình dự đoán của mẫu thứ i .

3.3 Kết quả thực nghiệm

3.3.1 So sánh hiệu năng các phương pháp trích xuất đặc trưng


Thực nghiệm được tiến hành bằng cách kết hợp chéo 3 loại đặc trưng (HOG, LBP, SIFT) với 3 mô hình học máy (SVR, Random Forest, MLP). Kết quả đánh giá hiệu năng trên tập kiểm thử (RMSE, MAE) và thời gian huấn luyện tương ứng được trình bày chi tiết trong Bảng 3.2.

Bảng 3.2: Kết quả đánh giá các cấu hình đặc trưng và mô hình.

Đặc trưng	Mô hình	RMSE	MAE	Thời gian (s)
HOG	RF	13.25	9.89	740.16
	SVR	12.65	9.15	910.99
	MLP	9.57	6.85	67.89
LBP	RF	16.37	12.43	1.02
	SVR	16.27	12.17	13.39
	MLP	15.94	12.14	32.92
SIFT	RF	17.89	13.68	12.12
	SVR	17.76	13.08	20.92
	MLP	22.31	17.19	30.10

Qua Bảng 3.2 và Hình 3.8, ta có thể rút ra một số nhận xét quan trọng:

- **Đặc trưng HOG vượt trội:** HOG cho kết quả tốt nhất ở tất cả các mô hình. Sự kết hợp giữa HOG và mạng nơ-ron đa tầng MLP đạt hiệu năng cao nhất trên toàn bộ thực nghiệm với MAE chỉ 6.85 tuổi. Điều




Hình 3.8: Biểu đồ so sánh RMSE và MAE của 3 phương pháp trích xuất đặc trưng với 3 mô hình học máy.

này cho thấy định hướng gradient của HOG nắm bắt rất tốt hình thái nếp nhăn và đường nét cấu trúc khuôn mặt - những yếu tố cốt lõi để nhận diện độ tuổi.

- LBP và SIFT kém hiệu quả hơn:** LBP mô tả tốt kết cấu bề mặt cục bộ nhưng thiếu thông tin về hình dáng tổng thể, dẫn đến sai số tương đối cao ($MAE > 12$). SIFT thậm chí cho kết quả thấp nhất, đặc biệt khi kết hợp với MLP ($MAE = 17.19$). Việc tính trung bình (mean) tất cả các SIFT descriptors trong ảnh đã làm mất đi thông tin phân bố không gian quan trọng của khuôn mặt.
- Đánh giá thời gian huấn luyện:** Đặc trưng HOG sinh ra vector có số chiều lớn, làm tăng đáng kể thời gian huấn luyện đối với SVR (910s) và Random Forest (740s). Ngược lại, mạng MLP lại tối ưu hóa dữ liệu nhiều chiều rất tốt, chỉ tốn khoảng 68s nhưng lại mang về độ chính xác vượt trội.

Từ kết quả này, cấu hình **HOG + MLP** được lựa chọn làm mô hình tốt nhất để phân tích và đánh giá chuyên sâu hơn. Hình 3.9 thể hiện biểu đồ

phân tán giữa tuổi thực tế và tuổi dự đoán của mô hình này. Phần lớn các điểm phân bố bám sát đường chéo trung tâm, chứng tỏ mô hình có khả năng hồi quy tuổi khá đồng đều.



Hình 3.9: Biểu đồ phân tán (Scatter Plot) giữa tuổi thực tế và tuổi dự đoán của mô hình HOG + MLP.

3.4 Tổng kết chương

Chương này đã trình bày chi tiết quá trình thực nghiệm, từ việc phân tích đặc điểm phân bố của tập dữ liệu UTKFace đến thiết lập môi trường và cấu hình thông số huấn luyện. Các kết quả đánh giá cho thấy mô hình mạng nơ-ron đa tầng (MLP) kết hợp với đặc trưng định hướng gradient (HOG) đạt hiệu năng vượt trội so với các phương pháp khác. Đây sẽ là cấu hình tốt nhất được sử dụng để tiến hành phân tích lỗi chuyên sâu đối với các nhóm yếu tố nhân khẩu học trong chương tiếp theo.


Chương 4. Thảo luận

Trong chương này, báo cáo sẽ tiến hành thảo luận và phân tích sâu hơn về các kết quả đạt được từ các thực nghiệm. Cụ thể, chương tập trung vào hai nội dung chính: đầu tiên là phân tích chi tiết lỗi sai của mô hình dự đoán tốt nhất (HOG + MLP) trên các khía cạnh nhân khẩu học bao gồm độ tuổi, giới tính và chủng tộc, nhằm hiểu rõ hơn về các giới hạn và nguyên nhân gây ra sai lệch đối với một số nhóm đối tượng cụ thể; thứ hai là đánh giá ảnh hưởng của phương pháp giảm chiều dữ liệu PCA lên đặc trưng HOG, từ đó làm rõ tác động của việc nén dữ liệu đến hiệu năng dự đoán của các mô hình học máy khác nhau (SVR, Random Forest và MLP).

4.1 Phân tích lỗi sai

Phần này đánh giá chi tiết sai số dự đoán của mô hình tốt nhất (HOG + MLP) trên các nhóm thuộc tính nhân khẩu học để xác định các giới hạn của mô hình.

4.1.1 Sai số theo nhóm tuổi



Hình 4.1: Sai số dự đoán (MAE) phân loại theo từng nhóm tuổi.

Dựa vào Hình 4.1, sai số dự đoán có xu hướng tăng dần theo độ tuổi. Nhóm trẻ em (0-5 tuổi) có MAE thấp nhất (3.4). Nhóm thanh niên (21-30 tuổi) đạt MAE là 5.3. Ngược lại, mức sai số tăng mạnh ở các độ tuổi cao, đạt 12.7 ở nhóm 61-80 tuổi và 14.6 ở nhóm trên 80 tuổi. Sự gia tăng sai số này phản ánh độ phân tán lớn của đặc điểm lão hóa ở người cao tuổi và số lượng mẫu huấn luyện ít hơn so với nhóm thanh niên.

4.1.2 Sai số theo giới tính




Hình 4.2: Sai số dự đoán (MAE) phân loại theo giới tính.

Hình 4.2 cho thấy MAE của nhóm nữ là 6.71, thấp hơn so với nhóm nam là 6.97. Mức chênh lệch 0.26 là rất nhỏ. Kết quả này cho thấy mô hình dự đoán đồng đều và không bị chênh lệch lớn giữa hai giới tính.


4.1.3 Sai số theo chủng tộc

Phân tích Hình 4.3, chủng tộc White có sai số trung bình cao nhất (MAE = 7.66), tiếp đến là Black (7.07). Các chủng tộc Asian và Others có mức sai số thấp nhất (5.57 và 5.56).

Biểu đồ violin (Hình 4.4) giải thích lý do nhóm White và Black có MAE cao: phân bố sai số của hai nhóm này có phần đuôi dài (nhiều mẫu có sai



Hình 4.3: Sai số dự đoán (MAE) trung bình theo từng chủng tộc.




Hình 4.4: Mật độ và phân tán của sai số dự đoán theo từng chủng tộc.

số dự đoán lên tới 40-60 tuổi). Nhóm Asian có phân bố tập trung chủ yếu ở mức sai số thấp dưới 20 tuổi.


Khi phân tích chi tiết theo từng độ tuổi trong mỗi chủng tộc (Hình 4.5), mô hình gặp khó khăn lớn nhất ở các nhóm cao tuổi thuộc các chủng tộc thiểu số. Cụ thể, nhóm 80+ của chủng tộc Others có sai số cực đại là 27.8, nhóm 80+ của Black có sai số 20.1. Nhóm White 80+ có sai số 13.9. Sự thiếu hụt dữ liệu huấn luyện cho người cao tuổi ở các chủng tộc này là nguyên nhân chính dẫn đến sai lệch lớn.

4.1.4 Đánh giá phương pháp huấn luyện chung và riêng rẽ



Hình 4.6: So sánh MAE khi huấn luyện chung toàn bộ dữ liệu và huấn luyện riêng rẽ cho từng chủng tộc.

Hình 4.6 so sánh hiệu năng giữa một mô hình được huấn luyện trên toàn bộ dữ liệu ("Chung") và 5 mô hình được huấn luyện độc lập trên dữ liệu của từng chủng tộc ("Riêng rẽ"). Kết quả cho thấy mô hình "Chung" đạt MAE thấp hơn ở tất cả các nhóm chủng tộc. Ví dụ, chủng tộc White giảm sai số từ 8.25 xuống 7.66; chủng tộc Indian giảm từ 7.07 xuống 6.21. Điều này chứng minh rằng việc kết hợp toàn bộ dữ liệu giúp mô hình học được các đặc điểm lão hóa tổng quát tốt hơn. Việc chia nhỏ dữ liệu để huấn luyện riêng rẽ làm giảm kích thước tập huấn luyện, dẫn đến hiệu năng dự đoán kém hơn.



Hình 4.5: Phân tích MAE theo nhóm tuổi cho từng chủng tộc.

4.2 Phân tích khả năng giảm chiều dữ liệu


Đặc trưng HOG có số chiều lớn, làm tăng thời gian tính toán của các mô hình như SVR và Random Forest. Phương pháp Phân tích Thành phần Chính (PCA) được sử dụng để giảm số chiều vector xuống các mức từ 10 đến 400 chiều.

Bảng 4.1: Đánh giá RMSE của các mô hình theo mức độ giảm chiều PCA.

Số chiều	MLP	RF	SVR	Số chiều	MLP	RF	SVR
10	14.881	14.615	14.673	210	11.628	13.446	13.327
20	14.409	13.722	13.395	220	11.762	13.485	13.360
30	13.936	13.274	12.347	230	11.956	13.478	13.467
40	14.106	13.203	12.223	240	11.710	13.488	13.575
50	14.145	13.233	12.315	250	11.696	13.509	13.692
60	13.543	13.282	12.268	260	11.868	13.515	13.764
70	13.401	13.291	12.381	270	11.876	13.513	13.860
80	13.099	13.266	12.386	280	11.585	13.547	13.951
90	12.747	13.296	12.420	290	11.642	13.519	14.044
100	12.504	13.318	12.513	300	11.687	13.537	14.119
110	12.543	13.315	12.524	310	11.496	13.532	14.241
120	12.251	13.356	12.611	320	11.751	13.561	14.337
130	12.428	13.377	12.673	330	11.511	13.549	14.453
140	12.162	13.374	12.742	340	11.588	13.573	14.487
150	12.152	13.387	12.803	350	11.587	13.599	14.594
160	12.127	13.410	12.871	360	11.592	13.597	14.696
170	12.053	13.412	12.992	370	11.468	13.579	14.762
180	12.143	13.406	13.037	380	11.635	13.607	14.807
190	11.845	13.414	13.131	390	11.386	13.606	14.926
200	12.025	13.440	13.221	400	11.651	13.595	14.972
				Gốc (8100D)	9.570	13.250	12.650

Dựa trên dữ liệu từ Hình 4.7 và Bảng 4.1:

- **Mô hình SVR:** SVR không dùng PCA đạt RMSE 12.65. Khi nén PCA



Hình 4.7: So sánh sai số RMSE theo số lượng thành phần chính (PCA) trên 3 mô hình.

xuống 40 chiều, RMSE của SVR giảm xuống mức tối ưu là 12.223. Đồ thị Hình 4.7 cho thấy đường biểu diễn của SVR đạt đáy tại 40 chiều và tăng dần khi số chiều cao hơn. PCA loại bỏ nhiễu và thông tin thừa, giúp SVR hoạt động chính xác và nhanh hơn đáng kể.

- **Mô hình Random Forest:** Đường biểu diễn của RF đi ngang ở mức 13.2 đến 13.6 từ mốc 40 chiều trở đi, tương tự như khi dùng dữ liệu gốc. PCA không làm thay đổi lớn hiệu năng của mô hình này do bản chất cấu trúc cây quyết định (decision tree) đã bao gồm khả năng chọn lọc đặc trưng.
- **Mô hình MLP:** MLP có xu hướng giảm dần sai số khi số lượng thành phần chính tăng lên và đạt mức tốt nhất là 11.386 tại 390 chiều. Tuy nhiên, kết quả này vẫn kém xa so với RMSE 9.570 khi sử dụng dữ liệu nguyên bản chưa nén. Khác với SVR, kiến trúc mạng nơ-ron đa tầng có khả năng tự động trích xuất các đặc trưng phi tuyến ẩn sâu từ dữ liệu thô cực kỳ tốt. Việc nén dữ liệu bằng phép chiếu tuyến tính như PCA trước khi đưa vào MLP đã vô tình loại bỏ nhiều thông tin quan trọng.

4.3 Tổng kết chương

Chương này đã đi sâu vào thảo luận và phân tích các nguyên nhân gây ra sai lệch của mô hình dự đoán. Kết quả chỉ ra rằng sự thiếu hụt dữ liệu và độ phân tán lớn về đặc điểm lão hóa là nguyên nhân chính khiến mô hình gặp khó khăn với người cao tuổi và các chủng tộc thiểu số. Đồng thời, qua thực nghiệm giảm chiều dữ liệu, PCA được chứng minh là hữu ích để tối ưu thời gian tính toán cho mô hình học máy truyền thống như SVR, trong khi lại làm suy giảm đáng kể hiệu năng của mạng nơ-ron (MLP) do làm mất đi các thông tin phi tuyến quan trọng.

Chương 5. Kết luận và Hướng phát triển

5.1 Kết luận

Tiểu luận này đã hoàn thành mục tiêu nghiên cứu và xây dựng quy trình hồi quy tuổi từ ảnh khuôn mặt. Dựa trên tập dữ liệu chuẩn UTKFace, nhóm đã thực hiện đánh giá toàn diện từ khâu phân tích, tiền xử lý dữ liệu đến trích xuất đặc trưng và tối ưu hóa mô hình học máy. Một số kết luận chính được rút ra như sau:

- **Hiệu quả của phương pháp trích xuất đặc trưng:** Đặc trưng định hướng gradient (HOG) tỏ ra vượt trội so với LBP và SIFT trong việc nắm bắt cấu trúc hình thái khuôn mặt để dự đoán độ tuổi. Khi kết hợp HOG với mạng nơ-ron đa tầng (MLP), mô hình đạt hiệu năng cao nhất với sai số tuyệt đối trung bình (MAE) là 6.85 tuổi.
- **Ảnh hưởng của mất cân bằng dữ liệu:** Phân tích lỗi chi tiết cho thấy mô hình hoạt động hiệu quả trên nhóm người trưởng thành trẻ tuổi và giới tính cân bằng. Tuy nhiên, sai số dự đoán tăng mạnh đối với nhóm người cao tuổi (đặc biệt trên 80 tuổi) và các chủng tộc thiểu số (như Black, Others). Nguyên nhân chính là do sự thiếu hụt mẫu huấn luyện và độ phân tán lớn của đặc điểm lão hóa ở các nhóm này.
- **Tác động của giảm chiều dữ liệu (PCA):** Phương pháp PCA đóng vai trò quan trọng trong việc loại bỏ nhiễu và giảm thời gian tính toán đối với mô hình SVR (khi giảm xuống 40 chiều, RMSE của SVR giảm từ 12.65 xuống 12.22). Ngược lại, đối với mạng MLP có khả năng tự động học các biểu diễn phức tạp, việc nén dữ liệu bằng phép chiếu tuyến tính như PCA làm suy giảm thông tin và giảm độ chính xác tổng thể so với dữ liệu gốc.

Nhìn chung, mô hình HOG kết hợp MLP là một giải pháp khá tốt, có tốc độ huấn luyện nhanh và mang lại độ chính xác khả quan đối với dữ liệu thực

tế. Tuy nhiên, những hạn chế khi đối diện với nhóm đối tượng thiểu số vẫn là một thách thức lớn cần giải quyết.

5.2 Hướng phát triển

Từ những kết quả và hạn chế đã được thảo luận, một số hướng phát triển tiềm năng trong tương lai để cải thiện độ chính xác và tính bền vững của mô hình bao gồm:

- **Khắc phục vấn đề mất cân bằng dữ liệu:** Áp dụng các kỹ thuật tăng cường dữ liệu, SMOTE hoặc GANs để bổ sung mẫu khuôn mặt cho nhóm người cao tuổi và các chủng tộc thiểu số. Bên cạnh đó, có thể thiết kế lại hàm mất mát bằng cách gán trọng số cao hơn cho các nhóm dữ liệu có tần suất xuất hiện thấp để mô hình tập trung tối ưu cho các nhóm này.
- **Sử dụng Deep Learning:** Thay vì dựa vào các đặc trưng thiết kế thủ công như HOG, nghiên cứu trong tương lai có thể sử dụng các mạng nơ-ron tích chập (CNN) sâu đã được huấn luyện trước trên tập dữ liệu khuôn mặt quy mô lớn (như VGGFace, ResNet) để tự động trích xuất các đặc trưng biểu diễn mức cao phong phú hơn.
- **Chuyển đổi cách tiếp cận bài toán:** Khai thác bài toán dự đoán tuổi dưới dạng phân loại thứ tự (Ordinal Regression) hoặc dự đoán một phân bố xác suất tuổi (Label Distribution Learning) thay vì chỉ hỏi quy ra một giá trị điểm duy nhất. Các phương pháp này đã được các nghiên cứu chứng minh là phản ánh tốt hơn tính chất thay đổi liên tục của quá trình lão hóa.
- **Đánh giá chéo trên nhiều bộ dữ liệu:** Mở rộng việc kiểm thử mô hình trên các bộ dữ liệu đa dạng hơn ngoài UTKFace (như MORPH-II, FG-NET, v.v.) để kiểm chứng độ mạnh mẽ và khả năng tổng quát hóa trong các điều kiện chụp ảnh phức tạp như thiếu sáng, góc chụp nghiêng, hay bị che khuất.

Tài liệu tham khảo

- [1] Rasmus Rothe, Radu Timofte, and Luc Van Gool. “DEX: Deep Expectation of Apparent Age from a Single Image”. In: *Proceedings of the IEEE International Conference on Computer Vision Workshops (ICCVW)*. 2015, pp. 252–257.
- [2] Zhifei Zhang et al. “Age Progression/Regression by Conditional Adversarial Autoencoder”. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2017, pp. 5810–5818.
- [3] Gil Levi and Tal Hassner. “Age and Gender Classification Using Convolutional Neural Networks”. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*. 2015, pp. 34–42.
- [4] Navneet Dalal and Bill Triggs. “Histograms of Oriented Gradients for Human Detection”. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2005, pp. 886–893.
- [5] Timo Ojala, Matti Pietikainen, and Topi Maenpaa. “Multiresolution Gray-Scale and Rotation Invariant Texture Classification with Local Binary Patterns”. In: *IEEE Transactions on Pattern Analysis and Machine Intelligence* 24.7 (2002), pp. 971–987.
- [6] David G. Lowe. “Distinctive Image Features from Scale-Invariant Keypoints”. In: *International Journal of Computer Vision* 60.2 (2004), pp. 91–110.
- [7] Ian T. Jolliffe. *Principal Component Analysis*. 2nd ed. Springer, 2002.
- [8] Harris Drucker et al. “Support Vector Regression Machines”. In: *Advances in Neural Information Processing Systems* 9 (1997), pp. 155–161.
- [9] Leo Breiman. “Random Forests”. In: *Machine Learning* 45.1 (2001), pp. 5–32.

- [10] Christopher M. Bishop. *Neural Networks for Pattern Recognition*. Oxford University Press, 1995.
- [11] Zhifei Zhang, Yang Song, and Hairong Qi. “Age Progression/Regression by Conditional Adversarial Autoencoder”. In: *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2017.
- [12] *UTKFace*. Kaggle dataset. Accessed: 2026-05-02. URL: <https://www.kaggle.com/datasets/jangedoo/utkface-new>.